

1. (20 pts) Gaussian noise as a regularizer

For a set of samples $(x_1, y_1) \dots, (x_n, y_n)$ with $x_i \in R$ and $y_i \in R$, we defined in class the problem of polynomial curve fitting as an error-minimization problem. Assume that the labels $\{y_i\}_{i=1}^N$ are i.i.d. and are drawn from a Gaussian distribution with a mean that is the prediction of the model $h_w(x)$, and a standard deviation σ . Formally, $y_i \sim \mathcal{N}(h_w(x_i), \sigma)$.

Show that maximizing the log of the likelihood $P(y_1, \dots, y_n | w)$ is equivalent to minimizing the squared error $Err(w) = \frac{1}{n} \sum_{i=1}^n (h_w(x_i) - y_i)^2$ used in class. Recall that the likelihood of a dataset $S_n = \{x_1, \dots, x_n\}$ is defined as $\mathcal{L} = P(S | w)$.

Hint: No need to compute any derivatives.

.1

בהוכחה זו נראה שה w שמביא למקסימום של \log של הlikelihood של $\log(P(y_1, \dots, y_n | w))$ מקביל ל w שמביא למינימום של $Err(w) = \frac{1}{n} \sum_{i=1}^n (h_w(x_i) - y_i)^2$

$$\log(P(y_1, \dots, y_n | w))$$

נשים לב כי מכיוון שנתון כי $\{y_i\}_{i=1}^N$ הינם בלתי תלויים לכן $P(y_1, \dots, y_n | w) = \prod_{i=1}^n P(y_i | w)$ ומכיוון שנתון כי $y_i \sim \mathcal{N}(h_w(x_i), \sigma)$ למעשה נקבל

$$\begin{aligned} \log(P(y_1, \dots, y_n | w)) &= \log\left(\prod_{i=1}^n P(y_i | w)\right) = \sum_{i=1}^n \log\left(\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y_i - h_w(x_i)}{\sigma}\right)^2}\right) \\ &= \sum_{i=1}^n \log\left(e^{-\frac{1}{2}\left(\frac{y_i - h_w(x_i)}{\sigma}\right)^2}\right) - \log(\sigma\sqrt{2\pi}) \\ &= \log(e) \sum_{i=1}^n \left(-\frac{1}{2}\left(\frac{y_i - h_w(x_i)}{\sigma}\right)^2\right) - n \log(\sigma\sqrt{2\pi}) \\ &= -n \log(\sigma\sqrt{2\pi}) + \frac{1}{2\sigma^2} \log(e) \cdot \left(-\sum_{i=1}^n (h_w(x_i) - y_i)^2\right) \end{aligned}$$

כעת נשים לב כי על מנת למצוא את המקסימום של הביטוי שקיבלנו אזי עלינו למצוא את w שממקסם את הביטוי ולכן מכיוון ש $-n \log(\sigma\sqrt{2\pi})$ הינו קבוע שנוסף לפונקציה ואינו תלוי ב w לכן נתעלם ממנו במציאת w שיתן מקסימום, כמו כן נתעלם מהקבוע $\frac{1}{2\sigma^2} \log(e)$ זאת מכיוון שהוא קבוע שכופל את החלק המשתנה של הפונקציה $(-\sum_{i=1}^n (h_w(x_i) - y_i)^2)$.

וכעת נשים לב כי בפונקציה $Err(w)$ גם נתעלם $\frac{1}{n}$ במציאת המינימום מכיוון שהוא קבוע שכופל את החלק המשתנה של הפונקציה $\sum_{i=1}^n (h_w(x_i) - y_i)^2$.

ולכן סה"כ קיבלנו כי w שממקסם את הביטוי $(-\sum_{i=1}^n (h_w(x_i) - y_i)^2)$ הינו w שמביא למינימום את הביטוי $\sum_{i=1}^n (h_w(x_i) - y_i)^2$ זאת מכיוון שהם אותם ביטויים רק אחד הוא כפול מינוס 1, כלומר מחליף את המקסימום למינימום. ולכן סה"כ הוכחנו כי w שמביא למקסימום של \log של הlikelihood של $\log(P(y_1, \dots, y_n | w))$ מקביל ל w שמביא למינימום של $Err(w) = \frac{1}{n} \sum_{i=1}^n (h_w(x_i) - y_i)^2$ כדרוש.

2. (12 pts) Bayesian decision theory

Show that for the squared cost function $\lambda(\hat{\theta}|\theta) = (\hat{\theta} - \theta)^2$, the optimal Bayes estimator is the conditional expectation.

$$\hat{\theta}_{SE} = E(\theta|S_n) = \int_{-\infty}^{\infty} \theta P(\theta|S_n) d\theta \quad .$$

Hint: The derivative operator is a linear operator, so it can switch order with the integral (you can use the Leibniz integral rule).

2. נוכיח כי עבור פונקציית ה-cost $\lambda(\hat{\theta}|\theta) = (\hat{\theta} - \theta)^2$ נקבל שה-Bayes estimator האופטימלי הוא בעצם conditional expectation. נמצא נקודת קיצון מסוג מינימום ו ע"י גזירה (לפי $\hat{\theta}$) והשוואה לס של הנגזרת. וכך למעשה נוכל לקבל את ה-Bayes estimator המינימלי (האופטימלי). ונוכיח כי נקבל $\hat{\theta}$ כך שיביא למינימום של ה-Bayes estimator והוא יהיה למעשה ה conditional expectation. במעבר הראשון נשתמש בכלל האינטגרל של לייבניץ.

$$\begin{aligned} \frac{d}{d\hat{\theta}} \int_{-\infty}^{\infty} (\hat{\theta} - \theta)^2 P(\theta|S_n) d\theta &= \int_{-\infty}^{\infty} \frac{d}{d\hat{\theta}} (\hat{\theta} - \theta)^2 P(\theta|S_n) d\theta = \int_{-\infty}^{\infty} \frac{d}{d\hat{\theta}} (\hat{\theta}^2 - 2\theta\hat{\theta} + \theta^2) P(\theta|S_n) d\theta \\ &= \int_{-\infty}^{\infty} \frac{d}{d\hat{\theta}} \hat{\theta}^2 P(\theta|S_n) - 2\theta\hat{\theta} P(\theta|S_n) + \theta^2 P(\theta|S_n) d\theta = \int_{-\infty}^{\infty} 2\hat{\theta} P(\theta|S_n) - 2\theta P(\theta|S_n) d\theta \end{aligned}$$

↓

$$\begin{aligned} \int_{-\infty}^{\infty} 2\hat{\theta} P(\theta|S_n) - 2\theta P(\theta|S_n) d\theta &= 0 \\ \int_{-\infty}^{\infty} 2\hat{\theta} P(\theta|S_n) d\theta &= \int_{-\infty}^{\infty} 2\theta P(\theta|S_n) d\theta \\ \int_{-\infty}^{\infty} \hat{\theta} P(\theta|S_n) d\theta &= \int_{-\infty}^{\infty} \theta P(\theta|S_n) d\theta \\ \hat{\theta} \int_{-\infty}^{\infty} P(\theta|S_n) d\theta &= \int_{-\infty}^{\infty} \theta P(\theta|S_n) d\theta \end{aligned}$$

נשים לב ש- $\int_{-\infty}^{\infty} P(\theta|S_n) d\theta = 1$ מאחר ומדובר באינטגרל של פונקציית הצפיפות ממיוס אינסוף ועד אינסוף ולפי הגדרה אינטגרל זה שווה ל 1. ונקבל

$$\hat{\theta} = \int_{-\infty}^{\infty} \theta P(\theta|S_n) d\theta$$

כעת נגזור שוב ונבדוק האם הנגזרת השנייה חיובית וכך נוכיח למעשה שזו אכן $\hat{\theta}$ שתביא למינימום את ה conditional expectation.

$$\begin{aligned} \frac{d}{d\hat{\theta}} \int_{-\infty}^{\infty} 2\hat{\theta}P(\theta|S_n) - 2\theta P(\theta|S_n) d\theta &= \int_{-\infty}^{\infty} \frac{d}{d\hat{\theta}} (\hat{\theta} - \theta) 2P(\theta|S_n) d\theta = \int_{-\infty}^{\infty} 2P(\theta|S_n) d\theta = 2 \int_{-\infty}^{\infty} P(\theta|S_n) d\theta \\ &= 2 > 0 \end{aligned}$$

ואכן קיבלנו כי הנגזרת השנייה חיובית לכל $\hat{\theta}$ ובפרט עבור $\hat{\theta} = \int_{-\infty}^{\infty} \theta P(\theta|S_n) d\theta$ ונקבל $\hat{\theta}$ כך שיביא למינימום של Bayes estimator והוא למעשה ה conditional expectation כדרוש.

4. (28 pts) Maximum likelihood estimation

Let $S_n = \{x_1, \dots, x_n\}$ be a random sample from the distributions below. Find the maximum likelihood estimate of the parameter θ .

(a) Poisson: $P(k|\theta) = \frac{\theta^k}{k!} \exp(-\theta)$ for $k = 0, 1, \dots$

(b) Exponential: $P(x|\theta) = \frac{1}{\theta} \exp(-x/\theta)$ for $x \geq 0$.

(c) $P(x|\theta) = \frac{1}{2} \exp(-|x - \theta|)$.

(d) $P(x|\theta) = \theta x^{\theta-1}$.

4. a. נמצא את המקסימום של ההערכת $likelihood$ של הפרמטר θ עבור התפלגות פואסיונית של $S_n = \{x_1, \dots, x_n\}$. כלומר נמצא את המקסימום של ההסתברות הבאה (נשים לב כי מכיוון שהדוגמאות הינם שרירותיות לכן גם בלתי תלויות ולכן נקבל כפל בין ההסתברויות שלהם):

$$P(S_n|\theta) = \prod_{i=1}^n \frac{\theta^{x_i}}{x_i!} e^{-\theta}$$

נוכל לבצע \ln על שני הצדדים ומכיוון \ln הינה מונוטונית עולה לכן הפרמטר θ שעבורו נקבל את המקסימום של \ln של שני צידי המשוואה יתן גם את המקסימום של $P(k|\theta)$ אם נציבו.

$$\ln(P(S_n|\theta)) = \ln\left(\prod_{i=1}^n \frac{\theta^{x_i}}{x_i!} e^{-\theta}\right) = \sum_{i=1}^n (\ln(\theta^{x_i}) + \ln(e^{-\theta}) - \ln(x_i!)) = \sum_{i=1}^n (x_i \cdot \ln(\theta) - \theta - \ln(x_i!))$$

כעת נגזור את הפונקציה הזו על מנת למצוא מקסימום:

$$\frac{d}{d\theta} \left(\sum_{i=1}^n (x_i \cdot \ln(\theta) - \theta - \ln(x_i!)) \right) = \sum_{i=1}^n x_i$$

ומכיוון שנתון כי בהתפלגות זו $x_i \geq 0$ לכל $1 \leq i \leq n$ לכן למעשה קיבלנו שהנגזרת הינה חיובית לכל θ ולכן נקבל כי הפונקציה $\sum_{i=1}^n (x_i \cdot \ln(\theta) - \theta - \ln(x_i!))$ הינה מונוטונית לא יורדת ולכן למעשה נקבל את המקסימום של פונקציה זו כאשר $\theta \rightarrow \infty$ וכפי שהסברנו למעלה נקבל גם את המקסימום של $likelihood$ שאותו חיפשנו. כלומר (נתון כי $x_i \geq 0$ בהתפלגות זו):

$$\max(P(S_n|\theta)) = \lim_{\theta \rightarrow \infty} P(S_n|\theta) = \lim_{\theta \rightarrow \infty} \prod_{i=1}^n \frac{\theta^{x_i}}{x_i!} e^{-\theta} = \infty$$

b. נמצא את המקסימום של ההערכת $likelihood$ של הפרמטר θ עבור התפלגות אקפוננציאלית של $S_n = \{x_1, \dots, x_n\}$. כלומר נמצא את המקסימום של ההסתברות הבאה (נשים לב כי מכיוון שהדוגמאות הינם שרירותיות לכן גם בלתי תלויות ולכן נקבל כפל בין ההסתברויות שלהם):

$$P(S_n|\theta) = \prod_{i=1}^n \frac{1}{\theta} e^{-\frac{x_i}{\theta}}$$

נוכל לבצע \ln על שני הצדדים ומכיוון \ln הינה מונוטונית עולה לכן הפרמטר θ שעבורו נקבל את המקסימום של \ln של שני צידי המשוואה יתן גם את המקסימום של $P(S_n|\theta)$ אם נציבו.

$$\ln(P(S_n|\theta)) = \ln\left(\prod_{i=1}^n \frac{1}{\theta} e^{-\frac{x_i}{\theta}}\right) = \sum_{i=1}^n (\ln(e^{-\frac{x_i}{\theta}}) - \ln(\theta)) = \sum_{i=1}^n \left(-\frac{x_i}{\theta}\right) - n \cdot \ln(\theta)$$

כעת נגזור את הביטוי ונחפש את θ שיביא למקסימום של פונקציה זו.

$$\frac{d}{d\theta} \left(\sum_{i=1}^n \left(-\frac{x_i}{\theta} \right) - n \cdot \ln(\theta) \right) = \sum_{i=1}^n \left(\frac{x_i}{\theta^2} \right) - \frac{n}{\theta}$$

נשווה ל-0 את הנגזרת הנ"ל:

$$\sum_{i=1}^n \left(\frac{x_i}{\theta^2} \right) - \frac{n}{\theta} = 0 \rightarrow \sum_{i=1}^n (x_i) - n \cdot \theta = 0 \rightarrow \theta = \frac{\sum_{i=1}^n x_i}{n}$$

כעת נשים לב להתנהגות הפונקציה $\prod_{i=1}^n \frac{1}{\theta} e^{-\frac{x_i}{\theta}}$ וכי עבור θ מאוד גדולים (גדולים מ- $\frac{\sum_{i=1}^n x_i}{n}$) אזי נקבל כי הביטוי $\frac{1}{\theta} e^{-\frac{x_i}{\theta}}$ ילך ויקטן ולכן הפונקציה תרד עבור θ מאוד גדולים כאשר הם הולכים וגדלים. כמו כן עבור ערכי θ קטנים (קטנים מ- $\frac{\sum_{i=1}^n x_i}{n}$ וגדולים מ-0) אשר גדלים לאט ניתן לשים לב כי הביטוי $\frac{1}{\theta} e^{-\frac{x_i}{\theta}}$ ילך ויגדל ולכן הפונקציה תעלה עבור θ מאוד קטנים כאשר הם הולכים וגדלים.

וסה"כ קיבלנו כי לפונקציה זו ישנה נקודת קיצון מסוג מקסימום וכעת נמצא את הערך המקסימלי שמתקבל עבור θ זו שמצאנו.

$$\max (P(S_n|\theta)) = \prod_{i=1}^n \frac{1}{\sum_{j=1}^n \frac{x_j}{n}} e^{-\frac{x_i}{\sum_{j=1}^n \frac{x_j}{n}}}$$

c. נמצא את המקסימום של ההערכת *likelihood* של הפרמטר θ עבור ההתפלגות הנ"ל של $S_n = \{x_1, \dots, x_n\}$. כלומר נמצא את המקסימום של ההסתברות הבאה (נשים לב כי מכיוון שהדוגמאות הינם שרירותיות לכן גם בלתי תלויות ולכן נקבל כפל בין ההסתברויות שלהם):

$$P(S_n|\theta) = \prod_{i=1}^n \frac{1}{2} e^{-|x_i - \theta|}$$

נוכל לבצע \ln על שני הצדדים ומכיוון ש \ln הינה מונוטונית עולה לכן הפרמטר θ שעבורו נקבל את המקסימום של \ln של שני צידי המשוואה יתן גם את המקסימום של $P(k|\theta)$ אם נציבו.

$$\ln(P(S_n|\theta)) = \ln \left(\prod_{i=1}^n \frac{1}{2} e^{-|x_i - \theta|} \right) = \sum_{i=1}^n (\ln(1) - \ln(2) - \ln(e^{-|x_i - \theta|})) = \sum_{i=1}^n (|x_i - \theta| - \ln(2))$$

נסדר את ערכי x כך שיהיו מסודרים בסדר עולה ($x_i < x_j$ לכל $1 \leq i < j \leq n$) ויהי $k \in \mathbb{N}$ $1 \leq k \leq n$. נשים לב כי הפונקציה $\sum_{i=1}^n (|x_i - \theta| - \ln(2))$ היא בעצם בעלת ערך מקסימום מכיוון שנשים לב כי עבור θ קטנים, כלומר אם קיימים יותר x_i כך ש $x_i > \theta$ מאשר כאלו ש $x_i \leq \theta$ אזי נקבל כי הנגזרת הינה מספר חיובי קבוע כלשהו, כלומר הנגזרת חיובית ולכן הפונקציה עולה וזה עבור θ קטנים. ועבור θ גדולים, כלומר אם קיימים פחות x_i כך ש $x_i > \theta$ מאשר כאלו ש $x_i \leq \theta$ אזי נקבל כי הנגזרת הינה מספר שלילי קבוע כלשהו, כלומר הנגזרת שלילית ולכן הפונקציה יורדת וזה עבור θ גדולים. וסה"כ קיבלנו כי קיים ערך מקסימום לפונקציה זו ולכן אנו נמצא את ערך θ עבורו ההערכת *likelihood* תהיה מקסימלית ע"י גזירה והשוואה ל-0. כעת נחלק למקרים (לא נתייחס למקרים שבהם θ גדול או שווה מכל ערכי x_i ובמקרה שבו θ קטן או שווה מכל ערכי x_i , מכיוון שבערכים אלו בהכרח לא נקבל נגזרת שווה ל-0 בהכרח מכיוון שערך הנגזרות יהיה n או $-n$ בהתאמה וכפי שידוע אנו מתעסקים עם $n > 0$).

עבור n אי זוגי:

- אם $x_1, \dots, x_k < \theta < x_{k+1}, \dots, x_n$:

$$\sum_{i=1}^n (|x_i - \theta| - \ln(2)) = \left(\sum_{i=1}^k (\theta - x_i) + \sum_{i=k+1}^n (x_i - \theta) - n \cdot \ln(2) \right)$$

נגזור לפי θ ונשווה ל-0:

$$\frac{d}{d\theta} \left(\sum_{i=1}^k (\theta - x_i) + \sum_{i=k+1}^n (x_i - \theta) - n \cdot \ln(2) \right) = k - (n - (k+1) + 1) = 2k - n$$

$$2k - n = 0$$

$$k = \frac{n}{2}$$

וקיבלנו סתירה לכך ש k טבעי כפי שהגדרנו מכיוון ש n הוא אי זוגי ולכן $\frac{n}{2}$ אינו טבעי, כלומר לא קיבלנו מקסימום במקרה זה.

- אם $x_1, \dots, x_{k-1} < (x_k = \theta) < x_{k+1}, \dots, x_n$ (במידה וקיימים גם עוד x_j עבורם $x_j = \theta$ אזי נוריד כפילויות אלה ונשאיר רק את $x_k = \theta$ ונעבור למקרה האי זוגי או הזוגי עם n חדש לאחר הורדת הכפילויות):

$$\sum_{i=1}^n (|x_i - \theta| - \ln(2)) = \left(\sum_{i=1}^{k-1} (\theta - x_i) + \sum_{i=k+1}^n (x_i - \theta) - n \cdot \ln(2) \right)$$

$$(\theta = x_k)$$

נגזור לפי θ ונשווה ל-0:

$$\frac{d}{d\theta} \left(\sum_{i=1}^{k-1} (\theta - x_i) + \sum_{i=k+1}^n (x_i - \theta) - n \cdot \ln(2) \right) = k - 1 - (n - (k+1) + 1) = 2k - n - 1$$

$$2k - n - 1 = 0$$

$$2k = n + 1$$

$$k = \frac{n+1}{2}$$

ובמקרה זה קיבלנו כי עבור $k = \frac{n+1}{2}$ אזי הנגזרת שווה ל-0 וכמו שהסברנו למעלה עבור $\theta = x_k = \frac{x_{n+1}}{2}$ (החציון

עבור n אי זוגי במקרה שלנו) אזי ערך ה $likelihood$ המקסימלי הוא $\max(P(S_n|\theta)) = \prod_{i=1}^n \frac{1}{2} e^{-|x_i - \frac{x_{n+1}}{2}|}$.

עבור n זוגי:

- אם $x_1, \dots, x_{k-1} < (x_k = \theta) < x_{k+1}, \dots, x_n$ (במידה וקיימים גם עוד x_j עבורם $x_j = \theta$ אזי נוריד כפילויות אלה ונשאיר רק את $x_k = \theta$ ונעבור למקרה האי זוגי או הזוגי עם n חדש לאחר הורדת הכפילויות):

$$\sum_{i=1}^n (|x_i - \theta| - \ln(2)) = \left(\sum_{i=1}^{k-1} (\theta - x_i) + \sum_{i=k+1}^n (x_i - \theta) - n \cdot \ln(2) \right)$$

$$(\theta = x_k)$$

נגזור לפי θ ונשווה ל-0:

$$\frac{d}{d\theta} \left(\sum_{i=1}^{k-1} (\theta - x_i) + \sum_{i=k+1}^n (x_i - \theta) - n \cdot \ln(2) \right) = k - 1 - (n - (k+1) + 1) = 2k - n - 1$$

$$2k - n - 1 = 0$$

$$2k = n + 1$$

$$k = \frac{n+1}{2}$$

וקיבלנו סתירה לכך ש k טבעי כפי שהגדרנו מכיוון ש $n+1$ הוא אי זוגי ולכן $\frac{n+1}{2}$ אינו טבעי, כלומר לא קיבלנו מקסימום במקרה זה.

- אם $x_1, \dots, x_k < \theta < x_{k+1}, \dots, x_n$

$$\sum_{i=1}^n (|x_i - \theta| - \ln(2)) = \left(\sum_{i=1}^k (\theta - x_i) + \sum_{i=k+1}^n (x_i - \theta) - n \cdot \ln(2) \right)$$

נגזור לפי θ ונשווה ל-0:

$$\frac{d}{d\theta} \left(\sum_{i=1}^k (\theta - x_i) + \sum_{i=k+1}^n (x_i - \theta) - n \cdot \ln(2) \right) = k - (n - (k+1) + 1) = 2k - n$$

$$2k - n = 0$$

$$k = \frac{n}{2}$$

ובמקרה זה קיבלנו כי עבור $k = \frac{n}{2}$ אזי הנגזרת שווה ל-0 וכמו שהסברנו למעלה עבור $x_k = x_{\frac{n}{2}} < \theta < x_{k+1} = x_{\frac{n}{2}+1}$

(החציון עבור n זוגי במקרה שלנו, נבחר את ערכו להיות ממש החציון - $\frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}$, אך כל ערך בין $x_{\frac{n}{2}}$ ל $x_{\frac{n}{2}+1}$

יהיה אופטימלי) אזי ערך ה $likelihood$ המקסימלי הוא $\max(P(S_n|\theta)) = \prod_{i=1}^n \frac{1}{2} e^{-|x_i - \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}|}$

וסה"כ גם למקרה ש n זוגי וגם למקרה שהוא אי זוגי קיבלנו כי החציון הוא אכן הפתרון האופטימלי $\theta = median\ of\ \{x_1, \dots, x_n\}$ להביא את ה $likelihood$ למקסימום.

d . נמצא את המקסימום של ההערכת ה $likelihood$ של הפרמטר θ עבור ההתפלגות הני"ל של $S_n = \{x_1, \dots, x_n\}$. כלומר נמצא את המקסימום של ההסתברות הבאה (נשים לב כי מכיוון שהדוגמאות הינם שרירותיות לכן גם בלתי תלויות ולכן נקבל כפל בין ההסתברויות שלהם):

$$P(S_n|\theta) = \prod_{i=1}^n \theta x_i^{\theta-1}$$

נוכל לבצע \ln על שני הצדדים ומכיוון ש \ln הינה מונוטונית עולה לכן הפרמטר θ שעבורו נקבל את המקסימום של \ln של שני צידי המשוואה יתן גם את המקסימום של $P(S_n|\theta)$ אם נציבו.

$$\ln(P(S_n|\theta)) = \ln\left(\prod_{i=1}^n \theta x_i^{\theta-1}\right) = \sum_{i=1}^n (\ln(\theta) + \ln(x_i^{\theta-1})) = n \ln(\theta) + (\theta - 1) \sum_{i=1}^n \ln(x_i)$$

כעת נגזור את הביטוי ונחפש את θ שיביא למקסימום של פונקציה זו.

$$\frac{d}{d\theta} \left(n \ln(\theta) + (\theta - 1) \sum_{i=1}^n \ln(x_i) \right) = \frac{n}{\theta} + \sum_{i=1}^n \ln(x_i)$$

נשווה ל-0 את הנגזרת הני"ל:

$$\frac{n}{\theta} + \sum_{i=1}^n \ln(x_i) = 0 \rightarrow \theta = - \sum_{i=1}^n \frac{n}{\ln(x_i)}$$

כעת אם נגזור שוב את הנגזרת נקבל:

$$\frac{d}{d\theta} \left(\frac{n}{\theta} + \sum_{i=1}^n \ln(x_i) \right) = -\frac{n}{\theta^2}$$

כעת נשים לב כי עבור כל θ ובפרט עבור ה- θ שמצאנו שעבורה הנגזרת שווה ל-0 אזי הנגזרת השנייה שלילית ולכן סה"כ קיבלנו כי לפונקציה זו ישנה נקודת קיצון מסוג מקסימום וכעת נמצא את הערך המקסימלי שמתקבל עבור θ זו שמצאנו.

$$\max (P(S_n|\theta)) = \prod_{i=1}^n \left(-\sum_{j=1}^n \frac{n}{\ln(x_j)} \right) x_i^{-\sum_{j=1}^n \frac{n}{\ln(x_j)} - 1}$$

5. (20 pts) Bayesian decision boundary

Let X be an R.V. with a Gaussian distribution, where $P(x|\omega = 1) = \mathcal{N}(\mu_1, \sigma_1^2)$ and $P(x|\omega = 2) = \mathcal{N}(\mu_2, \sigma_2^2)$. σ_1 and σ_2 may not be identical. Assuming the prior is uniform $P(\omega = 1) = P(\omega = 2)$, find the decision boundary as a function of x , and the parameters $\mu_1, \mu_2, \sigma_1, \sigma_2$.

5. תחילה נתון כי X מתפלג נורמלית ומתקיים $P(x|w = 1) = N(\mu_1, \sigma_1^2)$ ו $P(x|w = 2) = N(\mu_2, \sigma_2^2)$. כמו כן נתון כי σ_1, σ_2 לא בהכרח זהים וכי התפלגות ה $prior$ הינה יוניפורמית, כלומר $P(w = 1) = P(w = 2)$. כמו כן נניח שפונקציה העלות הינה $zero - one - lost$ כלומר מתקיים $\frac{\lambda_{22} - \lambda_{12}}{\lambda_{11} - \lambda_{21}} = \frac{0-1}{0-1} = 1$ ונמצא את ה $decision boundary$ כפונקציה של x , כלומר עבור ערכי x שמקיימים את האי השוויון הבא, נבחר במצב העולם $w = 1$ ועבור שאר ערכי x נבחר במצב העולם $w = 2$:

$$\frac{P(x|w = 1)}{P(x|w = 2)} > \frac{P(w = 2)\lambda_{22} - \lambda_{12}}{P(w = 1)\lambda_{11} - \lambda_{21}}$$

$$\frac{P(x|w = 1)}{P(x|w = 2)} > 1$$

$$\frac{\frac{1}{\sigma_1 \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{x - \mu_1}{\sigma_1} \right)^2}}{\frac{1}{\sigma_2 \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{x - \mu_2}{\sigma_2} \right)^2}} > 1$$

$$\frac{\sigma_2}{\sigma_1} e^{\frac{1}{2} \left(\frac{x - \mu_2}{\sigma_2} \right)^2 - \frac{1}{2} \left(\frac{x - \mu_1}{\sigma_1} \right)^2} > 1$$

$$e^{\frac{1}{2} \left(\frac{x - \mu_2}{\sigma_2} \right)^2 - \frac{1}{2} \left(\frac{x - \mu_1}{\sigma_1} \right)^2} > \frac{\sigma_1}{\sigma_2}$$

$$\ln \left(e^{\frac{1}{2} \left(\frac{x - \mu_2}{\sigma_2} \right)^2 - \frac{1}{2} \left(\frac{x - \mu_1}{\sigma_1} \right)^2} \right) > \ln \left(\frac{\sigma_1}{\sigma_2} \right)$$

$$\frac{1}{2} \left(\frac{x - \mu_2}{\sigma_2} \right)^2 - \frac{1}{2} \left(\frac{x - \mu_1}{\sigma_1} \right)^2 > \ln \left(\frac{\sigma_1}{\sigma_2} \right)$$

$$\sigma_1^2 x^2 - 2\sigma_1^2 x \mu_2 + \sigma_1^2 \mu_2^2 - \sigma_2^2 x^2 + 2\sigma_2^2 x \mu_1 - \sigma_2^2 \mu_1^2 > 2\sigma_1^2 \sigma_2^2 \ln \left(\frac{\sigma_1}{\sigma_2} \right)$$

$$(\sigma_1^2 - \sigma_2^2)x^2 + (2\sigma_2^2 \mu_1 - 2\sigma_1^2 \mu_2)x + (\sigma_1^2 \mu_2^2 - \sigma_2^2 \mu_1^2 - 2\sigma_1^2 \sigma_2^2 \ln \left(\frac{\sigma_1}{\sigma_2} \right)) > 0$$

כעת נבצע נוסחת שורשים-

$$x_{1,2} = \frac{-(2\sigma_2^2 \mu_1 - 2\sigma_1^2 \mu_2) \pm \sqrt{(2\sigma_2^2 \mu_1 - 2\sigma_1^2 \mu_2)^2 - 4(\sigma_1^2 - \sigma_2^2) \left(\sigma_1^2 \mu_2^2 - \sigma_2^2 \mu_1^2 - 2\sigma_1^2 \sigma_2^2 \ln \left(\frac{\sigma_1}{\sigma_2} \right) \right)}}{2(\sigma_1^2 - \sigma_2^2)}$$

$$\begin{aligned}
&= \frac{-(2\sigma_2^2\mu_1 - 2\sigma_1^2\mu_2) + \sqrt{-4\sigma_2^2\mu_1\sigma_1^2\mu_2 + 4\sigma_1^2\sigma_2^2\mu_1^2 + 8\sigma_1^4\sigma_2^2 \ln\left(\frac{\sigma_1}{\sigma_2}\right) + 4\sigma_1^2\sigma_2^2\mu_2^2 - 8\sigma_1^2\sigma_2^4 \ln\left(\frac{\sigma_1}{\sigma_2}\right)}}{2(\sigma_1^2 - \sigma_2^2)} \\
&= \frac{-(2\sigma_2^2\mu_1 - 2\sigma_1^2\mu_2) + \sqrt{4\sigma_1^2\sigma_2^2\left(-\mu_1\mu_2 + \mu_1^2 + 2\sigma_1^2 \ln\left(\frac{\sigma_1}{\sigma_2}\right) + \mu_2^2 - 2\sigma_2^2 \ln\left(\frac{\sigma_1}{\sigma_2}\right)\right)}}{2(\sigma_1^2 - \sigma_2^2)} \\
&= \frac{-(2\sigma_2^2\mu_1 - 2\sigma_1^2\mu_2) + 2\sigma_1\sigma_2\sqrt{-\mu_1\mu_2 + \mu_1^2 + 2\sigma_1^2 \ln\left(\frac{\sigma_1}{\sigma_2}\right) + \mu_2^2 - 2\sigma_2^2 \ln\left(\frac{\sigma_1}{\sigma_2}\right)}}{2(\sigma_1^2 - \sigma_2^2)}
\end{aligned}$$

כעת נפצל למקרים-

- אם $(\sigma_1^2 - \sigma_2^2)$ חיובי אזי נקבל פרבולה "מחייכת" ולכן $(\sigma_1^2 - \sigma_2^2)x^2 + (2\sigma_2^2\mu_1 - 2\sigma_1^2\mu_2)x + \left(\sigma_1^2\mu_2^2 - \sigma_2^2\mu_1^2 - 2\sigma_1^2\sigma_2^2 \ln\left(\frac{\sigma_1}{\sigma_2}\right)\right) > 0$ מתקיים עבור:

- אם נקבל כי באמת קיימים $x_{1,2}$ שמקיימים את משוואת השורשים ונניח בלי הגבלת הכלליות כי $x_1 < x_2$ אזי נקבל כי עבור ערכי x שמקיימים $x_1 < x < x_2$ או $x > x_2$ הפונקציה הנ"ל חיובית ומקיימת את אי השוויון ואלו בעצם ערכי x עבורם נבחר במצב העולם $w = 1$.
- אם נקבל כי קיים x_1 שמקיים את משוואת השורשים אזי נקבל כי עבור ערכי x שמקיימים $x \neq x_1$ הפונקציה הנ"ל חיובית ומקיימת את אי השוויון ואלו בעצם ערכי x עבורם נבחר במצב העולם $w = 1$.
- אם נקבל כי לא קיים x שמקיימים את משוואת השורשים אזי נקבל כי עבור כל ערכי x הפונקציה הנ"ל חיובית ומקיימת את אי השוויון ואלו בעצם ערכי x עבורם נבחר במצב העולם $w = 1$.

- אם $(\sigma_1^2 - \sigma_2^2)$ שלילי אזי נקבל פרבולה "עצובה" ולכן $(\sigma_1^2 - \sigma_2^2)x^2 + (2\sigma_2^2\mu_1 - 2\sigma_1^2\mu_2)x + \left(\sigma_1^2\mu_2^2 - \sigma_2^2\mu_1^2 - 2\sigma_1^2\sigma_2^2 \ln\left(\frac{\sigma_1}{\sigma_2}\right)\right) > 0$ מתקיים עבור:

- אם נקבל כי באמת קיימים $x_{1,2}$ שמקיימים את משוואת השורשים ונניח בלי הגבלת הכלליות כי $x_1 < x_2$ אזי נקבל כי עבור ערכי x שמקיימים $x_1 < x < x_2$ הפונקציה הנ"ל חיובית ומקיימת את אי השוויון ואלו בעצם ערכי x עבורם נבחר במצב העולם $w = 1$.
- אם נקבל כי קיים x_1 שמקיים את משוואת השורשים אזי נקבל כי לא קיים x עבורו הפונקציה הנ"ל חיובית ומקיימת את אי השוויון ולכן לא קיימים ערכי x עבורם נבחר במצב העולם $w = 1$.
- אם נקבל כי לא קיים x שמקיימים את משוואת השורשים אזי נקבל כי לא קיים x עבורו הפונקציה הנ"ל חיובית ומקיימת את אי השוויון ולכן לא קיימים ערכי x עבורם נבחר במצב העולם $w = 1$.